

Analisi di Immagini e Video (Computer Vision)

Giuseppe Manco

Outline

- Preliminari
- Classificazione
 - Esempio: regressione logistica
- Quali features?

Crediti

- Slides adattate da vari corsi e libri
 - Analisi di Immagini (F. Angiulli) – Unical
 - Intro to Computer Vision (J. Tompkin) – CS Brown Edu
 - Computer Vision (I. Gkioulekas) - CS CMU Edu
 - Computational Visual Recognition (V. Ordonez), CS Virginia Edu
 - Pattern Recognition and Machine Learning (C. Bishop, 2005)
 - Deep Learning (Bengio, Courville, Goodfellow, 2017)

Supervised, unsupervised e semi-supervised
learning

$$y = f(x)$$

Supervised, unsupervised e semi-supervised learning

$$y = f(x)$$

- f di forma non nota
- x campionato da un dominio X e y campionato da un dominio Y
- Tipicamente, $x \in \mathbb{R}^n$

Supervised, unsupervised e semi-supervised learning

$$y = f(x)$$

- f di forma non nota
- x campionato da un dominio X e y campionato da un dominio Y
- Tipicamente, $x \in \mathbb{R}^n$
- **Supervised Learning**
 - Apprendi f da $D \subset X \times Y$

Supervised, unsupervised e semi-supervised learning

$$y = f(x)$$

- f di forma non nota
- x campionato da un dominio X e y campionato da un dominio Y
- Tipicamente, $x \in \mathbb{R}^n$
- **Supervised Learning**
 - Apprendi f da $D \subset X \times Y$
- **Unsupervised Learning**
 - Apprendi f da $D \subset X$

Supervised, unsupervised e semi-supervised learning

$$y = f(x)$$

- f di forma non nota
- x campionato da un dominio X e y campionato da un dominio Y
- Tipicamente, $x \in \mathbb{R}^n$
- **Supervised Learning**
 - Apprendi f da $D \subset X \times Y$
- **Semi-supervised Learning**
 - Apprendi f da $D = (D_1, D_2)$ dove $D_1 \subset X \times Y$ e $D_2 \subset X$

Supervised, unsupervised e semi-supervised learning

$$y = f(x)$$

- f di forma non nota
- x campionato da un dominio X e y campionato da un dominio Y
- Tipicamente, $x \in \mathbb{R}^n$

$$f(x) \equiv f(x; \theta) \equiv f_{\theta}(x)$$

- $\theta \in \Theta$ parametro scelto dal parameter space Θ (il **linguaggio**)

Inferenza vs. Learning

- **Stima/Apprendimento:** Selezionare
 - I parametri più appropriati
 - Una distribuzione sui parametri
 - Un insieme di distribuzioni
- **Inferenza:**
 - Predizioni
 - Statistiche
 - Valori attesi
 - Margini di un modello statistico

Supervised, unsupervised e semi-supervised learning

$$y = f(x)$$

- f di forma non nota
- x campionato da un dominio X e y campionato da un dominio Y
- Tipicamente, $x \in \mathbb{R}^n$

$$f(x) \equiv f(x; \theta) \equiv f_{\theta}(x)$$

- $\theta \in \Theta$ parametro scelto dal parameter space Θ (il **linguaggio**)
- **Cos'è y ?**

Supervised, unsupervised e semi-supervised learning

$$y = f(x)$$


- Cos'è y ?
- Una classe

$$\text{cat} = f(\text{)}$$

Supervised, unsupervised e semi-supervised learning

$$y = f(x)$$

- Cos'è y ?
- Un insieme finito di regioni



Supervised, unsupervised e semi-supervised learning

$$y = f(x)$$

- Cos'è y ?
- Segmenti



$$= f($$




$$)$$

Inferenza vs. Learning

- **Stima/Apprendimento:** Selezionare
 - I parametri più appropriati
 - Una distribuzione sui parametri
 - Un insieme di distribuzioni
- **Inferenza:**
 - Predizioni
 - Statistiche
 - Valori attesi
 - Margini di un modello statistico

Training, Validation, Test Sets



D

Training, Validation (Dev), Test Sets



D_{train}

Usato nella fase di learning

Training, Validation (Dev), Test Sets




Usato nella fase di valutazione

D_{test}

Classificazione

Classificazione

Training Set



•
•
•



cat

dog

cat

bear

Test Set



•
•
•



Classificazione

Training Set

$$x_1 = [\text{img1}] \quad y_1 = [\text{cat}]$$

$$x_2 = [\text{img2}] \quad y_2 = [\text{dog}]$$

$$x_3 = [\text{img3}] \quad y_3 = [\text{cat}]$$

•
•
•

$$x_n = [\text{img4}] \quad y_n = [\text{bear}]$$

Classificazione

Training Set

inputs

targets /
ground truth

Predizioni

$$x_1 = [x_{11} \ x_{12} \ x_{13} \ x_{14}]$$

$$y_1 = 1$$

$$\hat{y}_1 = 1$$

$$x_2 = [x_{21} \ x_{22} \ x_{23} \ x_{24}]$$

$$y_2 = 2$$

$$\hat{y}_2 = 2$$

$$x_3 = [x_{31} \ x_{32} \ x_{33} \ x_{34}]$$

$$y_3 = 1$$

$$\hat{y}_3 = 2$$

•
•
•

$$x_n = [x_{n1} \ x_{n2} \ x_{n3} \ x_{n4}]$$

$$y_n = 3$$

$$\hat{y}_n = 1$$

Dato il parametro θ possiamo calcolare \hat{y}

$$\hat{y} = f_{\theta}(x)$$

Problema:

Come trovare il parametro θ ?

Soluzione:

Funzione di costo

$$loss = \sum_i Cost(y_i, \hat{y}_i)$$

Modello lineare di classificazione

- Caso semplice: classificazione binaria

- $y \in \{0,1\}$

- (o $y \in \{1,2\}$, $y \in \{-1,1\}$, ...)

- Il decision boundary tra due classi è un iperpiano nello spazio delle features

- Le due regioni sono separate dall'iperpiano

$$w_1x_1 + w_2x_2 + \cdots w_mx_m = b$$

Regressione logistica

Training Data

inputs

targets /
labels /
ground truth

$$x_1 = [x_{11} \ x_{12} \ x_{13} \ x_{14}] \quad y_1 = 1$$

$$x_2 = [x_{21} \ x_{22} \ x_{23} \ x_{24}] \quad y_2 = 2$$

$$x_3 = [x_{31} \ x_{32} \ x_{33} \ x_{34}] \quad y_3 = 1$$

•
•
•

$$x_n = [x_{n1} \ x_{n2} \ x_{n3} \ x_{n4}] \quad y_n = 2$$

Regressione logistica

Training Data

inputs	targets / labels / ground truth	predizioni
$x_1 = [x_{11} \ x_{12} \ x_{13} \ x_{14}]$	$y_1 = 1$	$\hat{y}_1 = [0.80 \ 0.10]$
$x_2 = [x_{21} \ x_{22} \ x_{23} \ x_{24}]$	$y_2 = 0$	$\hat{y}_2 = [0.30 \ 0.70]$
$x_3 = [x_{31} \ x_{32} \ x_{33} \ x_{34}]$	$y_3 = 1$	$\hat{y}_3 = [0.40 \ 0.60]$
•		
•		
•		
$x_n = [x_{n1} \ x_{n2} \ x_{n3} \ x_{n4}]$	$y_n = 0$	$\hat{y}_n = [0.650 \ 0.35]$

Regressione logistica

$$x_i = [x_{i1} \ x_{i2} \ x_{i3} \ x_{i4}] \quad y_i = 1 \quad \hat{y}_i = [f_1 \ f_2]$$

$$g_1 = w_1 x_{i1} + w_2 x_{i2} + w_3 x_{i3} + w_4 x_{i4} + b$$

Regressione logistica

$$x_i = [x_{i1} \ x_{i2} \ x_{i3} \ x_{i4}] \quad y_i = 1 \quad \hat{y}_i = [f_1 \ f_2]$$

$$\textit{logit} = w_1 x_{i1} + w_2 x_{i2} + w_3 x_{i3} + w_4 x_{i4} + b$$

- Cosa rappresenta \hat{y}_i ?
- Cosa è *logit*?

Regressione logistica

$$x_i = [x_{i1} \ x_{i2} \ x_{i3} \ x_{i4}] \quad y_i = 1 \quad \hat{y}_i = [f_1 \ f_2]$$

$$\text{logit} = w_1 x_{i1} + w_2 x_{i2} + w_3 x_{i3} + w_4 x_{i4} + b$$

- Cosa rappresenta \hat{y}_i ?
- Definiamo $f_\theta(x)$ come la funziona che fornisce le misure di probabilità per ogni classe

$$f_\theta(x) = [\Pr(y = 0|x, \theta), \Pr(y = 1|x, \theta)] \equiv [\Pr(\text{neg}|x, \theta), \Pr(\text{pos}|x, \theta)]$$

Regressione Logistica

- Preserva i classification boundaries lineari
- il decision boundary tra le classi pos e neg è determinato dalla seguente equazione:

$$\Pr(pos|x, \theta) = \Pr(neg|x, \theta)$$


- rapportando e prendendo il logaritmo...

$$\log \frac{\Pr(pos|x, \theta)}{\Pr(neg|x, \theta)} = 0$$

- poiché il bordo deve essere lineare,

$$\log \frac{\Pr(pos|x, \theta)}{\Pr(neg|x, \theta)} = b + \sum_j w_j x_{i,j}$$

- Il rapporto è chiamato log odds, o anche logit
 - $\theta = \{b, w_1, \dots, w_m\}$ è l'insieme dei parametri da apprendere



- dalla precedente, le probabilità a posteriori diventano:

$$\Pr(pos|x, \theta) = \frac{\exp(b + \sum_j w_j x_{i,j})}{1 + \exp(b + \sum_j w_j x_{i,j})}$$

$$\Pr(neg|x, \theta) = \frac{1}{1 + \exp(b + \sum_j w_j x_{i,j})}$$

- Le probabilità sommano a 1

- Introduciamo le funzioni

- Logistica

$$\sigma(x) = \frac{1}{1 + \exp(-x)}$$

- logit

$$\text{logit}(x; \theta) = b + \sum_j w_j x_{i,j}$$

- Riscriviamo le formule

$$\Pr(\text{pos}|x, \theta) = \sigma(\text{logit}(x; \theta))$$

$$\Pr(\text{neg}|x, \theta) = 1 - \sigma(\text{logit}(x; \theta))$$

Model learning

- Obiettivo

- trovare i parametri $\{b, w_1, \dots, w_m\}$ che massimizzano la verosimiglianza sul training set

$$\mathcal{L}(D, \theta) = \prod_{i=1}^n \Pr(y_i | x_i, \theta)$$

- Equivalentemente, minimizziamo

$$nll(D, \theta) = - \sum_{i=1}^n \log \Pr(y_i | x_i, \theta)$$

- Se $y_i = 1$ abbiamo

$$\begin{aligned}\log \Pr(y_i|x_i, \theta) &= \log \Pr(pos|x_i, \theta) \\ &= 1 \cdot \log \Pr(pos|x_i, \theta) \\ &= y_i \cdot \log \Pr(pos|x_i, \theta)\end{aligned}$$

- analogamente, se $y_i = 0$

$$\begin{aligned}\log \Pr(y_i|x_i, \theta) &= \log(1 - \Pr(pos|x_i, \theta)) \\ &= 1 \cdot \log (1 - \Pr(pos|x_i, \theta)) \\ &= (1 - y_i) \cdot \log \Pr(pos|x_i, \theta)\end{aligned}$$

- Poiché $y_i = 1$ oppure $y_i = 0$,

$$\log \Pr(y_i|x_i, \theta) = y_i \cdot \log \Pr(pos|x_i, \theta) + (1 - y_i) \cdot \log(1 - \Pr(pos|x_i, \theta))$$

- La verosimiglianza...

$$\begin{aligned} nll(D, \theta) &= - \sum_{i=1}^n \log \Pr(y_i | x, \theta) \\ &= - \sum_{i=1}^n \{ y_i \cdot \log \Pr(pos | x, \theta) + (1 - y_i) \cdot \log(1 - \Pr(pos | x, \theta)) \} \\ &= - \sum_{i=1}^n \{ y_i \cdot \log \hat{y}_i + (1 - y_i) \cdot \log(1 - \hat{y}_i) \} \\ &= - \sum_{i=1}^n Cost(y_i, \hat{y}_i) \end{aligned}$$

- Dove

- $\hat{y}_i = \Pr(pos | x, \theta)$
- $Cost(y_i, \hat{y}_i) = y_i \cdot \log \hat{y}_i + (1 - y_i) \cdot \log(1 - \hat{y}_i)$

Che succede se abbiamo più classi?

Training Data

inputs

targets /
labels /
ground truth

$$x_1 = [x_{11} \ x_{12} \ x_{13} \ x_{14}] \quad y_1 = 1$$

$$x_2 = [x_{21} \ x_{22} \ x_{23} \ x_{24}] \quad y_2 = 2$$

$$x_3 = [x_{31} \ x_{32} \ x_{33} \ x_{34}] \quad y_3 = 1$$

•
•
•

$$x_n = [x_{n1} \ x_{n2} \ x_{n3} \ x_{n4}] \quad y_n = 3$$

Che succede se abbiamo più classi?

Training Data

inputs

targets /
labels /
ground truth

Predizioni

$$x_1 = [x_{11} \ x_{12} \ x_{13} \ x_{14}]$$

$$y_1 = [1 \ 0 \ 0]$$

$$\hat{y}_1 = [0.85 \ 0.10 \ 0.05]$$

$$x_2 = [x_{21} \ x_{22} \ x_{23} \ x_{24}]$$

$$y_2 = [0 \ 1 \ 0]$$

$$\hat{y}_2 = [0.20 \ 0.70 \ 0.10]$$

$$x_3 = [x_{31} \ x_{32} \ x_{33} \ x_{34}]$$

$$y_3 = [1 \ 0 \ 0]$$

$$\hat{y}_3 = [0.40 \ 0.45 \ 0.15]$$

•
•
•

$$x_n = [x_{n1} \ x_{n2} \ x_{n3} \ x_{n4}]$$

$$y_n = [0 \ 0 \ 1]$$

$$\hat{y}_n = [0.40 \ 0.25 \ 0.35]$$

Che succede se abbiamo più classi?

- Un logit per ogni classe

$$x_i = [x_{i1} \ x_{i2} \ x_{i3} \ x_{i4}] \quad y_i = [1 \ 0 \ 0] \quad \hat{y}_i = [f_c \ f_d \ f_b]$$

$$g_c = w_{c1}x_{i1} + w_{c2}x_{i2} + w_{c3}x_{i3} + w_{c4}x_{i4} + b_c$$

$$g_d = w_{d1}x_{i1} + w_{d2}x_{i2} + w_{d3}x_{i3} + w_{d4}x_{i4} + b_d$$

$$g_b = w_{b1}x_{i1} + w_{b2}x_{i2} + w_{b3}x_{i3} + w_{b4}x_{i4} + b_b$$

$$f_c = e^{g_c} / (e^{g_c} + e^{g_d} + e^{g_b})$$

$$f_d = e^{g_d} / (e^{g_c} + e^{g_d} + e^{g_b})$$

$$f_b = e^{g_b} / (e^{g_c} + e^{g_d} + e^{g_b})$$

Che succede se abbiamo più classi?

- La loss può essere adattata

$$nll(D, \theta) = - \sum_{i=1}^n Cost(y_i, \hat{y}_i)$$

$$Cost(y_i, \hat{y}_i) = \sum_{j=1}^k y_{i,j} \cdot \log \hat{y}_{i,j}$$

$$\hat{y}_{i,j} = \Pr(y_{i,j} = 1 | x_i, \theta) = softmax_j(x_i; \theta)$$

$$softmax_j(x_i; \theta) = \frac{\exp(logit_j(x_i, \theta))}{\sum_{h=1}^k \exp(logit_h(x_i, \theta))}$$

Ottimizziamo la funzione di costo

$$nll(D, \theta) = - \sum_{i=1}^n Cost(y_i, \hat{y}_i)$$

- Due strade:
 - Gradient-Descent (primo ordine)
 - Newton-Raphson (secondo ordine)

Gradiente discendente

$$l(\theta) \equiv nll(D, \theta) = - \sum_{i=1}^n Cost(y_i, \hat{y}_i)$$

- Dato λ (learning rate) e N (numero di epoche)

Inizializza θ_0 in maniera random
for e in range(N)

$$\theta_{e+1} \leftarrow \theta_e - \lambda \frac{\partial l(\theta_e)}{\partial \theta}$$

Idea di fondo

- Per valori opportuni di λ produce una sequenza $l(\theta_0) \geq l(\theta_1) \dots \geq l(\theta_e)$
- Perché funziona?
 - Approssimazione in serie di Taylor al primo ordine


$$l(\theta) \approx l(\theta_e) + (\theta - \theta_e)^T \frac{\partial l(\theta_e)}{\partial \theta}$$

- Calcolato sul punto θ_{e+1} e assumendo l'update


$$\begin{aligned} l(\theta_{e+1}) &\approx l(\theta_e) + (\theta_{e+1} - \theta_e)^T \frac{\partial l(\theta_e)}{\partial \theta} \\ &= l(\theta_e) - \lambda \cdot \left\| \frac{\partial l(\theta_e)}{\partial \theta} \right\|^2 \end{aligned}$$

- Il termine $\left\| \frac{\partial l(\theta_e)}{\partial \theta} \right\|^2$ è sempre positivo


Idea di base



Idea



Idea



Gradiente discendente

$$l(\theta) \equiv nll(D, \theta) = - \sum_{i=1}^n \text{Cost}(y_i, \hat{y}_i)$$

costoso

- Dato λ (learning rate) e N (numero di epoche)

Inizializza θ_0 in maniera random
for e in range(N)

$$\theta_{e+1} \leftarrow \theta_e - \lambda \frac{\partial l(\theta_e)}{\partial \theta}$$

Minibatch (stochastic) GD

$$l_B(\theta) = - \sum_{i \in B} Cost(y_i, \hat{y}_i)$$

- Dato λ (learning rate) e N (numero di epoche), M (numero di batches)

```
Inizializza  $\theta_0$  in maniera random  
for e in range(N)  
    for b in range(M)  
         $\theta_{e+1} \leftarrow \theta_e - \frac{\lambda}{B} \frac{\partial l_{B_b}(\theta_e)}{\partial \theta}$ 
```


Learning

- Gradient Descent

$$\theta_{e+1} \leftarrow \theta_e - \lambda \frac{\partial l(\theta_e)}{\partial \theta}$$


- Stochastic GD

$$\theta_{e+1} \leftarrow \theta_e - \frac{\lambda}{N} \frac{\partial l_i(\theta_e)}{\partial \theta}$$

- Mini-batch SGD

$$\theta_{e+1} \leftarrow \theta_e - \frac{\lambda}{B} \sum_{i \in B} \frac{\partial l_i(\theta_e)}{\partial \theta}$$

$$\left. \begin{array}{l} \theta_{e+1} \leftarrow \theta_e - \frac{\lambda}{N} \frac{\partial l_i(\theta_e)}{\partial \theta} \\ \theta_{e+1} \leftarrow \theta_e - \frac{\lambda}{B} \sum_{i \in B} \frac{\partial l_i(\theta_e)}{\partial \theta} \end{array} \right\} l_i(\theta) = \text{Cost}(y_i, \hat{y}_i)$$



More to come later ...

- Regularization
- Momentum updates
- Hinge Loss, Least Squares Loss, Logistic Regression Loss...

Riassumendo



↓ Estraiamo le features

$$x_i = [x_{i1} \ x_{i2} \ x_{i3} \ x_{i4}]$$

↓ Calcoliamo i logits

$$g_c = w_{c1}x_{i1} + w_{c2}x_{i2} + w_{c3}x_{i3} + w_{c4}x_{i4} + b_c$$

$$g_d = w_{d1}x_{i1} + w_{d2}x_{i2} + w_{d3}x_{i3} + w_{d4}x_{i4} + b_d$$

$$g_b = w_{b1}x_{i1} + w_{b2}x_{i2} + w_{b3}x_{i3} + w_{b4}x_{i4} + b_b$$

$$f_c = e^{g_c} / (e^{g_c} + e^{g_d} + e^{g_b})$$

$$f_d = e^{g_d} / (e^{g_c} + e^{g_d} + e^{g_b})$$

$$f_b = e^{g_b} / (e^{g_c} + e^{g_d} + e^{g_b})$$

$$\hat{y}_i = [f_c \ f_d \ f_b]$$

Otteniamo le
predizioni